

Домашнее задание 1

Дедлайн: 2025-02-04, 23:59.

- Случайные величины y_i независимы и одинаково распределены с $\mathbb{P}(y_i = 0) = a$, $\mathbb{P}(y_i = 1) = 2a$, $\mathbb{P}(y_i = 2) = 1 - 3a$. В выборке y_1, y_2, \dots, y_n оказалось N_0 нулей, N_1 единиц и N_2 двоек.
 - Найдите оценку \hat{a} параметра a методом моментов используя $\mathbb{E}(y_i)$.
 - Найдите оценку \hat{a} параметра a методом моментов используя $\mathbb{E}(y_i^2)$.
 - Найдите оценку \hat{a} параметра a методом максимального правдоподобия.
- Случайные величины y_i независимы и нормально распределены $\mathcal{N}(2a; a)$ с неизвестным параметром a .
 - Найдите оценку \hat{a} параметра a методом моментов используя $\mathbb{E}(y_i)$.
 - Найдите оценку \hat{a} параметра a методом моментов используя $\mathbb{E}(y_i^2)$.
 - Найдите оценку \hat{a} параметра a методом максимального правдоподобия.
- В отделении банка 5 клиентских окошек. Время обслуживания каждого клиента имеет экспоненциальное распределение с неизвестной интенсивностью λ . Я был в очереди последним, и когда я встал к освободившемуся окошку номер 5, все остальные окошки ещё обслуживали клиентов. Через 3 минуты обслужили клиента в окошке 3, через 7 минут — клиента в окошке номер 4, а потом я освободился и ушёл.
 - Найдите оценку \hat{a} параметра a методом моментов, используя любое математическое ожидание.
 - Найдите оценку \hat{a} параметра a методом максимального правдоподобия.

Примечание: если в данной задаче возникает нерешаемое в явном виде уравнение, то, конечно, можно и нужно воспользоваться подходящим численным методом.

Домашнее задание 2

Дедлайн: 2025-02-23, 23:59.

Оцениваемые задачи:

- Величины y_1, y_2, \dots, y_n независимы и равномерны отрезке на $[0; a]$ с неизвестным $a > 5$. Никола Тесла хочет оценить неизвестный параметр $b = \mathbb{P}(y_i > 5)$. Рассмотрим две оценки: \hat{b}_n — доля наблюдений в выборке, оказавшихся больше 5 и $\hat{b}'_n = 1 - 2.5/\bar{y}$.
 - Является ли оценка \hat{b}_n несмещённой? состоятельной?
 - Является ли оценка \hat{b}'_n несмещённой? состоятельной?
- Величины y_i независимы и имеют функцию плотности

$$f(y) = \begin{cases} 3y^2/\theta^3, & \text{если } y \in [0; \theta]; \\ 0, & \text{иначе.} \end{cases}$$

- а) Найдите оценку $\hat{\theta}$ неизвестного параметра θ методом максимального правдоподобия.
- б) Является ли оценка $\hat{\theta}$ несмещённой?
- в) Является ли оценка $\hat{\theta}$ состоятельной?
- г) Найдите функцию плотности оценки $\hat{\theta}$.
- д) На какую величину нужно домножить оценку $\hat{\theta}$, чтобы она стала несмещённой?

Подсказка: ответ на пункт (б) можно получить без вычислений и интегралов :)

Неоцениваемые задачи в удовольствие:

3. Величина Y имеет биномиальное распределение $\text{Bin}(n, p)$.

- а) Является ли оценка $\hat{p} = Y/n$ для p несмещённой? Если является смещённой, то скорректируйте оценку так, чтобы она стала несмещённой.
- б) Чему равна теоретическая дисперсия σ^2 величины Y ?
- в) Является ли оценка $\hat{\sigma}^2 = n\hat{p}(1 - \hat{p})$ для σ^2 несмещённой? Если является смещённой, то скорректируйте оценку так, чтобы она стала несмещённой.

4. Величины X_i независимы и одинаково распределены с неизвестными $\mathbb{E}(X_i) = \mu$ и $\text{Var}(X_i) = \sigma^2$.

Рассмотрим четыре оценки:

$$\hat{\mu}_A = (X_1 + X_2)/2, \quad \hat{\mu}_B = (X_1 + X_2 + X_3)/3, \quad \hat{\mu}_C = 2X_1 - X_2, \quad \hat{\mu}_D = (X_1 + X_2 + \dots + X_{20})/21.$$

- а) Какая из приведенных оценок для μ является несмещённой?
 - б) У какой несмещённой оценки самая маленькая дисперсия?
 - в) Выберите наиболее эффективную оценку в этом множестве по критерию MSE , если $\sigma = 0.5\mu$.
5. Величины X_1 и X_2 независимы и равномерны на отрезке $[0; a]$ с неизвестным a и $Y = \min\{X_1, X_2\}$.
- а) При каком β оценка $\hat{a} = \beta Y$ для параметра a будет несмещённой?
 - б) При каком β оценка $\hat{a} = \beta Y$ для параметра a будет наиболее эффективной по критерию MSE ?

6. Величины X_i независимы и имеют закон распределения

x	0	1	a
$\mathbb{P}(X = x)$	1/4	1/4	2/4

- а) Постройте состоятельную оценку для неизвестного a .
- б) Возможно ли в этой задаче построить несмещённую оценку для a ?

Домашнее задание 3

Дедлайн: 2025-04-27, 23:59.

Оцениваемые задачи:

1. В одном тропическом лесу водятся удавы и питоны. Длина удавов имеет нормальное распределение $\mathcal{N}(\mu_X, \sigma_X^2)$. По выборке из 10 удавов оказалось, что $\sum X_i = 20$ метрам, а $\sum X_i^2 = 1000$. Длина питонов имеет нормальное распределение $\mathcal{N}(\mu_Y, \sigma_Y^2)$. По выборке из 20 питонов оказалось, что $\sum Y_i = 60$ метрам, а $\sum Y_i^2 = 4000$. Все наблюдения независимы между собой.
 - а) Постройте точечные оценки для $\mu_X, \sigma_X^2, \mu_Y, \sigma_Y^2$.
 - б) Постройте двусторонний 95%-й доверительный интервал для σ_X^2/σ_Y^2 .
 - в) Проверьте гипотезу $H_0: \sigma_X^2 = \sigma_Y^2$ против альтернативной $H_1: \sigma_Y^2 > \sigma_X^2$ на уровне значимости 5%. Укажите точное p -значение.
 - г) Постройте примерный двусторонний 95%-й доверительный интервал для разницы $\mu_X - \mu_Y$ с помощью статистики Уэлча.
 - д) Проверьте гипотезу $H_0: \mu_X = \mu_Y$ против альтернативной $H_1: \mu_Y > \mu_X$ на уровне значимости 5% с помощью теста Уэлча. Укажите точное p -значение.
2. Априорное распределение параметра θ является треугольным на отрезке $[0; 40]$ с модой в точке 30. Наблюдаемая величина X — это индикатор того, что $\theta > 20$. Оказалось, что $X = 1$.
 - а) Найдите апостериорную плотность θ .
 - б) Найдите апостериорное математическое ожидание θ .
 - в) Найдите апостериорную медиану θ .
 - г) Постройте 94% байесовский интервал наивысшей плотности для θ .
 - д) Постройте 94% симметричный по вероятности байесовский интервал для θ .

Определение треугольного распределения можно найти, например, на википедии :)

Неоцениваемые задачи в удовольствие:

3. Величины X_1, \dots, X_n независимы и одинаково распределены с функцией плотности

$$f(x) = \begin{cases} \theta x^{\theta-1}, & \text{при } x \in [0; 1] \\ 0, & \text{иначе.} \end{cases}$$

- а) Оцените значение θ с помощью метода максимального правдоподобия.
- б) Оцените дисперсию оценки $\hat{\theta}_{ML}$ метода максимального правдоподобия.
- в) Как примерно распределена $\hat{\theta}_{ML}$?
- г) Оцените значение θ с помощью метода моментов.
- д) Оцените дисперсию оценки $\hat{\theta}_{MM}$ метода моментов.
- е) Как примерно распределена $\hat{\theta}_{MM}$?

4. Цыганка Роза ничего не понимает в статистике, но у неё всегда с собой колода из 36 карт.

Помогите цыганке Розе построить точный 95%-й доверительный интервал для неизвестной вероятности p того, что клиента ждёт дальняя дорога и казённый дом.

5. Величины X_1, \dots, X_n независимы и одинаково распределены с функцией плотности

$$f(x) = \begin{cases} \frac{\theta \exp(-\theta^2/2x)}{\sqrt{2\pi x^3}} & \text{при } x \in [0; +\infty), \\ 0, & \text{иначе.} \end{cases}$$

- Найдите оценку параметра θ методом максимального правдоподобия, если по выборке из 100 наблюдений оказалось $\sum 1/X_i = 12$.
 - Найдите оценку параметра θ методом максимального правдоподобия для произвольной выборки.
 - Найдите теоретическую информацию Фишера $I(\theta)$.
 - Пользуясь данными по выборке постройте оценку \hat{I} для информации Фишера.
 - Постройте 90% доверительный интервал для θ . Подсказка: $\mathbb{E}(1/X_i) = 1/\theta^2$, интеграл берется, например, заменой $x = \theta^2 a^{-2}$.
6. Величины X_1 и X_2 независимы и распределены по Пуассону с интенсивностью a . Есть две гипотезы, $H_0: a = 1$ и $H_a: a = 2$. Мальвина отвергает H_0 в том случае, если $X_1 + X_2 \geq 2$. Найдите вероятность ошибок первого и второго рода.

7. Величины Y_1, \dots, Y_n независимы и имеют распределение Бернулли с неизвестным p , $\hat{p} = \bar{Y}$.

- Постройте для неизвестного p доверительный интервал Вальда. Для этого вспомните про сходимость

$$\frac{\hat{p} - p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \xrightarrow{\text{dist}} \mathcal{N}(0; 1)$$

и решите неравенство

$$-z_{\text{cr}} \leq \frac{\hat{p} - p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} \leq z_{\text{cr}}.$$

- Постройте для неизвестного p доверительный интервал Вильсона. Для этого воспользуйтесь сходимостью

$$\frac{\hat{p} - p}{\sqrt{\frac{p(1-p)}{n}}} \xrightarrow{\text{dist}} \mathcal{N}(0; 1).$$

На этот раз потребуется решить (о ужас!) квадратное неравенство.

Обозначим центр интервала Вильсона с помощью \hat{p}_w .

- Докажите, что центр интервала Вильсона \hat{p}_w можно представить как средневзвешенное классической оценки \hat{p} и тривиальной оценки $1/2$,

$$\hat{p}_w = u\hat{p} + (1-u)(1/2).$$

Найдите веса u и $(1-u)$.

- г) Докажите, что центр интервала Вильсона \hat{p}_w можно проинтерпретировать следующим образом: добавим f вымышленных единиц и f вымышленных нулей в выборку и посчитаем классическую оценку вероятности для выборки с вымышленными наблюдениями,

$$\hat{p}_w = \frac{\sum_{i=1}^n Y_i + f}{n + 2f}.$$

Какому целому числу примерно равно f для 95%-го доверительного интервала?

- д) Докажите, что интервал Вильсона можно записать в виде

$$\hat{p}_w \pm z_{\text{cr}} \cdot \sqrt{\frac{u\hat{p}(1-\hat{p}) + (1-u)(1/2)^2}{n_w}}.$$

Найдите n_w , а также веса u и $(1-u)$.

Таким образом, интервал Вильсона слегка корректирует число наблюдений и использует в качестве оценки дисперсии Y_i средневзвешенное между классической оценкой $\hat{p}(1-\hat{p})$ и тривиальной оценкой $1/4$.

Доверительный интервал Агрести — Коуллы для уровня доверия 95% строится следующим образом. В выборку мысленно добавляют два наблюдения равных единице и два наблюдения равных нулю, считают оценку доли

$$\hat{p}_{ac} = \frac{\sum_{i=1}^n Y_i + 2}{n + 4},$$

а затем строят классический интервал Вальда, используя \hat{p}_{ac} вместо классической \hat{p} .

- е) Правда ли, что при уровне доверия 95% центры интервала Агрести — Коуллы и Вильсона совпадают?
- ж) Какой 95%-й интервал шире, Агрести — Коуллы или Вильсона?
- з) С помощью симуляций на компьютере сравните фактическую вероятность накрытия неизвестного параметра p интервалами Вальда, Вильсона и Агрести — Коуллы с номинальной 95%-й вероятностью. Для экспериментов возьмите $n = 50$ и различные p от 0 до 1 с шагом 0.1.

Домашнее задание 4

Дедлайн: 2025-05-18, 23:59.

Оцениваемые задачи:

1. Величины (y_i) независимы и одинаково непрерывно распределены. Всего есть 1000 наблюдений. Постройте 95%-й интервал для 90%-го квантиля с помощью выборочных квантилей.
Если для вычисления необходимых выборочных квантилей использовался код, то приведите его.
2. Есть две выборки: $x = (2.7, 3.5, 4.2, 6.7)$ и $y = (1.6, 2.9, 3.9)$. Все наблюдения независимы. Величины (x_i) одинаково непрерывно распределены между собой, величины (y_i) одинаково непрерывно распределены между собой. Проверьте гипотезу H_0 об одинаковом законе распределения в двух выборках, против альтернативной $\mathbb{P}(x_i > y_j) > 0.5$ на уровне значимости 5%.
 - а) Проведите тест Манна — Уитни, используя точное распределение статистики.

- б) Проведите тест Манна — Уитни, используя нормальную аппроксимацию. Укажите p -значение.

Неоцениваемые задачи в удовольствие:

3. Рассмотрим тест знаковых рангов Уилкоксона и связанные пары наблюдений (x_i, y_i) . При верной H_0 разницы $D_i = x_i - y_i$ одинаково непрерывно распределены и независимы. Рассмотрим сумму знаковых рангов $WSR = \sum_{i=1}^n \text{sign}(D_i) \text{rank}(|D_i|)$. Найдите ожидание $\mathbb{E}(WSR)$ и дисперсию $\text{Var}(WSR)$ при верной H_0 .
4. Величины (X_i) независимы и одинаково распределены с неизвестными $\mathbb{E}(X_i) = \mu$ и $\text{Var}(X_i) = \sigma^2$. По выборке из 1000 наблюдений оказалось, что $\bar{X} = 30$, а несмещённая выборочная дисперсия равна 900.
- Постройте асимптотический 95%-й доверительный интервал для μ . Укажите p -значение для гипотезы $H_0: \mu = 35$ против альтернативной $H_a: \mu \neq 35$.
 - Постройте асимптотический 95%-й предсказательный интервал для X_{1001} .
 - Постройте асимптотический 95%-й предсказательный интервал для $(X_{1001} + X_{1002})/2$.
5. Бариста Борис заметил, что в последнее время посетители заказывают только капучино и раф. Предположим, что посетители выбирают напиток независимо друг от друга, а вероятность выбора капучино постоянна и равна неизвестному числу p . У Бориса есть только две гипотезы, $H_0: p = 1/3$ и $H_a: p = 2/3$, в которые он до получения данных верит с вероятностями 0.6 и 0.4, соответственно. Из первых 100 утренних посетителей $S = 40$ выбрали капучино. Борис хочет измерить разными способами, насколько этот наблюдаемый результат соотносится с гипотезами.
- Найдите $\mathbb{P}(H_0 \mid S = 40)$ и $\mathbb{P}(H_a \mid S = 40)$.
- Борис решил на следующий день повторить эксперимент и снова посчитать S_{new} , количество клиентов из первых ста, которые выберут капучино.
- Найдите $\mathbb{P}(S_{\text{new}} \geq S \mid S = 40, H_0)$ и $\mathbb{P}(S_{\text{new}} \geq S \mid S = 40, H_a)$.
 - Какие из вероятностей можно посчитать без мнения Бориса о $\mathbb{P}(H_0)$ и $\mathbb{P}(H_a)$?
 - Какая из вероятностей называется p -значением для гипотезы H_0 и статистики S ?
6. По таблице сопряжённости проверьте гипотезу о независимости двух признаков на уровне значимости 5% против альтернативной гипотезы о зависимости признаков. Укажите p -значение.

	$X = A$	$X = B$
$Y = C$	50	60
$Y = D$	20	30
$Y = E$	60	50

7. Рассмотрим таблицу сопряжённости

$X = A$	$X = B$	$X = C$	$X = D$
50	70	80	60

- а) На уровне значимости 5% проверьте гипотезу об одинаковых вероятностях $p_a = p_b = p_c = p_d$ против альтернативной о том, что хотя бы одно из равенств нарушено.
- б) На уровне значимости 5% проверьте гипотезу об одинаковых вероятностях $p_a = p_b = p_c = p_d$ против альтернативной о том, что $p_a \neq p_b = p_c$.
- в) На уровне значимости 5% проверьте гипотезу об одинаковых вероятностях $p_a = p_b = p_c$ против альтернативной о том, что $p_a \neq p_b = p_c$.

В каждом случае укажите p -значение.

Домашнее задание 5

Дедлайн: 2025-06-01, 23:59.

Оцениваемые задачи:

1. Величины (y_i) независимы и экспоненциально распределены с интенсивностью λ .
Количество наблюдений n велико. Тестируем гипотезу $H_0: \lambda = 2$ против альтернативы $\lambda \neq 2$.
 - а) Выведите формулы для теста отношения правдоподобия LR , теста множителей Лагранжа LM и теста Вальда W .
 - б) Проведите тесты для конкретной выборки с $n = 1000$, $\bar{y} = 2.2$ и уровня значимости 1%.
2. Величины (y_i) независимы и нормально распределены $\mathcal{N}(\mu, 1)$.
Количество наблюдений n велико. Тестируем гипотезу $H_0: \mu = 0$ против альтернативы $\mu \neq 0$.
 - а) Выведите формулы для теста отношения правдоподобия LR , теста множителей Лагранжа LM и теста Вальда W .
 - б) Проведите тесты для конкретной выборки с $n = 1000$, $\sum y_i = 1000$, $\sum y_i^2 = 4000$ и уровня значимости 1%.

Неоцениваемые задачи в удовольствие:

3. Гипотеза H_0 описывается 5-ю независимыми уравнениями, неограниченный максимум лог-правдоподобия равен $\ell_{UR} = -200$, а ограниченный — $\ell_R = -209$. Число наблюдений n велико. Альтернативная гипотеза состоит в том, что хотя бы одно уравнение не выполнено.
 - а) Отвергается ли H_0 на уровне значимости 1%?
 - б) Найдите p -значение.
4. Оценка неизвестного вектора параметров $a = (a_1, a_2, a_3)$ равна $\hat{a} = (1, 2, 3)$ с оценкой ковариационной матрицы

$$\widehat{\text{Var}}(\hat{a}) = \begin{pmatrix} 9 & -1 & 2 \\ & 16 & -1 \\ & & 10 \end{pmatrix}.$$

Число наблюдений велико. Рассмотрим гипотезу $H_0: a_1 = a_2 = a_3$ против альтернативы о том, что хотя бы одно уравнение не выполнено.

- а) Предложите естественную оценку \hat{b} для вектора $b = (a_1 - a_2, a_2 - a_3)$.
 - б) Оцените ковариационную матрицу $\widehat{\text{Var}}(\hat{b})$.
 - в) Переформулируйте H_0 в терминах вектора b .
 - г) Проведите тест Вальда гипотезы H_0 на уровне значимости 5%.
5. Мы оцениваем три неизвестных параметра, $(\theta_1, \theta_2, \theta_3)$. При максимизации с учётом ограничений гипотезы H_0 оказывается, что градиент лог-правдоподобия равен $\text{grad } \ell = (-0.1, 0.2, 0)$, а матрица Гессе в точке ограниченного экстремума равна

$$H = \begin{pmatrix} -5 & -2 & 0 \\ & -6 & 0 \\ & & -10 \end{pmatrix}$$

Число наблюдений велико.

- а) Чему равен градиент лог-правдоподобия в точке неограниченного экстремума?
 - б) Протестируйте H_0 на уровне значимости 1% с помощью теста множителей Лагранжа.
6. Вспомним классический хи-квадрат тест Пирсона на соответствие выборки заданному дискретному закону распределения со статистикой

$$S = \sum_{i=1}^k \frac{(f_i - np_i)^2}{np_i},$$

где k — число клеток таблицы, f_i — количество наблюдений, попавших в i -ую клетку таблицы, а p_1, p_2, \dots, p_k — вероятности, предполагаемые в H_0 .

С каким тестом ($LR/LM/W$) совпадает данная статистика?

Домашнее задание 6

Дедлайн: 2025-06-18, 23:59.

Оцениваемые задачи:

1. Случайные величины y_1, \dots, y_n независимы и одинаково распределены с $\mathbb{P}(y_i = 1) = p$ и $\mathbb{P}(y_i = 0) = 1 - p$. Рассмотрим бутстрэп-выборку y_1^*, \dots, y_n^* .
 - а) Найдите $\mathbb{P}(y_1^* = y_1)$ и $\mathbb{P}(y_1^* = y_2^*)$.
 - б) Найдите $\mathbb{E}(y_i^*)$ и $\text{Var}(y_i^*)$.
 - в) Найдите $\text{Cov}(y_1^*, y_2^*)$.
2. Винни-Пух хочет проверить 5 нулевых гипотез. Он посчитал p -значения для каждой из них, $p = (0.03, 0.04, 0.08, 0.15, 0.30)$.
 - а) Какие гипотезы отвергнет алгоритм Холма — Бонферонни, гарантирующий $FWER = 0.2$?
 - б) Какие гипотезы отвергнет алгоритм Беньямини — Хохберга, гарантирующий $FDR = 0.2$?

Неоцениваемые задачи в удовольствие:

3. Величины y_1, \dots, y_n независимы и одинаково распределены с функцией плотности

$$f(y) = \begin{cases} \exp(a - y) & \text{если } y \geq a, \\ 0, & \text{иначе.} \end{cases}$$

- а) Найдите оценку неизвестного параметра a методом максимального правдоподобия.
 - б) Какова фактическая вероятность накрытия параметра a при построении наивного бутстрэп доверительного интервала с номинальной вероятностью накрытия 95%?
4. Опишите алгоритм наивного бутстрэпа для построения 95% доверительного интервала для истинной медианы распределения.
5. У исследователя всего две нулевых гипотезы. Каждая из них априорно верна с вероятностью 0.2 независимо от других. При верной отдельной нулевой гипотезы H_j распределение соответствующей ей тестовой статистики непрерывно. Для упрощения будем считать, что если отдельная нулевая гипотеза H_j не верна, то её p -значение в точности равно 0.
- а) Вспомните, как распределено p -значение при верной нулевой гипотезе.
 - б) Рассмотрим алгоритм Холма — Бонферонни, гарантирующий $FWER = 0.2$. Какова условная вероятность того, что он отвергнет конкретную нулевую гипотезу с известным p -значением равным u ?
 - в) Рассмотрим алгоритм Беньямини — Хохберга, гарантирующий $FDR = 0.2$. Какова условная вероятность того, что он отвергнет конкретную нулевую гипотезу с известным p -значением равным u ?
6. В одном из вариантов бутстрэпа (subsampling bootstrap) в бутстрэп выборку попадает $m < n$ наблюдений без повторов из исходной выборки в n наблюдений. Предположим, что исходные n наблюдений y_1, y_2, \dots, y_n независимы и равномерны $\text{Unif}[0, 1]$. Рассмотрим бутстрэп выборку y_1^*, \dots, y_m^* .
- а) Как распределено y_i^* ?
 - б) Найдите $\text{Corr}(y_1^*, y_2^* \mid y_1, y_2, \dots, y_n)$.
 - в) Найдите $\text{Corr}(y_1^*, y_2^*)$.
-